Rabeb Kaabi

6 ans d'expérience

Senior Data Scientist spécialisée en Generative AI, MLOps, vision par ordinateur et NLP, Rabeb conçoit et industrialise des solutions d'IA robustes, innovantes et opérationnelles.Elle combine rigueur scientifique et expertise pratique, avec une forte expérience sur Google Cloud Platform : Vertex AI, Cloud Run et Agent Engine, pour déployer des modèles et architectures IA à grande échelle.

Certifications

GCP : "Generative AI Leader (Juillet 2025-Juillet 2028)"
Udemy "Udemy Google Cloud Machine Learning: Vertex AI (Septembre 2024)
Udemy MLOPS : Machine Learning Deployement (Septembre 2023)

Diplômes

Ingénierie en Informatique Industrielle -ENSIT
Doctorat en IA et computer vision
Seatech -Université de Toulon 2020)

Langues

Français
Anglais

Expériences clés récentes

Devoteam - Ecovadis ,Doctolib,Baobab Projet- IA Multi-Agents (GCP / ADK)

- **Conception et déploiement d'une solution IA multi-agents sur le framework ADK**, hébergée sur **Cloud Run** ,**Agent Engine** et Gemini Entreprise .
- Définition de l'architecture (A2A / MCP) et intégration de connecteurs vers Databricks et outils tiers.
- Animation de workshops clients pour le développement et le déploiement multi-agents

Octo(Filiale Accenture)-Ministère des Armées - Data/NLP Engineer

- Cadrage fonctionnel et technique des flux de données, garantissant la fiabilité et la traçabilité du référentiel RH sur l'ensemble du SI
- Conception d'un pipeline automatisé de nettoyage et normalisation des données
- Mise en production réussie de la solution dans un environnement sécurisé et maintenable, posant les bases d'une future exploitation IA du référentiel RH.

Compétences

- **Data Science & IA**
- Conception et industrialisation de solutions IA (vision, NLP, Generative AI) avec mise en production sur GCP (Vertex AI, Cloud Run, Agent Engine) et intégration MLOps complète.
- **Tech Lead**
- Pilotage technique de projets IA de bout en bout, du POC à la production.
- Encadrement d'équipes Data/ML et définition des bonnes pratiques MLOps (DVC, MLflow, GitHub Actions, CI/CD, Vertex AI Pipelines).
- Supervision du cycle de vie complet des modèles, incluant traçabilité, versioning et monitoring.
- **Collaboration & Cadrage**
- Cadrage des besoins métiers et traduction en solutions data-driven robustes.
- Coordination d'équipes pluridisciplinaires pour la mise en place de pipelines automatisés

Tech Lead Consultant -Devoteam G Cloud

06/ 2025-jusqu'à maintenant

Arturia
09/2025 - jusqu'à maintenant

Contexte

- **-Conception et développement d'un système de traduction automatique multilingue (**Markdown, HTML, emails) en conservant la mise en page complète : liens, images, tableaux, ancrages, styles.
- -Implémentation d'un support client automatisé avec compréhension contextuelle.
- -**Déploiement cloud-native :** Docker, Cloud Run, Artifact Registry, configuration de GCS et Mise en place des bonnes pratiques de sécurité et d'ingénierie :

Responsibilités

- **Tech Lead Consultant**

Environment Technique

- **Python**
- **Fast API , Docker**
- **GCP: Cloud Run, Google Cloud Storage,Artifact Registry, Google Cloud Storage**

Tech Lead Consultant -Devoteam G Cloud

06/2025 - jusqu'à maintenant

Contexte

- **Développement d'une solution multi-agents** : Conception et développement d'une **solution d'IA multi-agents personnalisée** sur **ADK** et **Agent Engine**, de la configuration initiale à l'intégration finale dans un environnement de production
- **Configuration de connecteurs** pour intégrer des applications propriétaires et tierces.
- **Développement de systèmes multi-agents** sur **Agentspace**.
- Intégration de technologies de pointe (**RAG**, **Prompt Engineering**, Protocoles : **A2A**, **MCP**).
- Garantie du **déploiement et du fonctionnement sans faille** de la solution.
- **Développement d'un agent de vérification des fournisseurs:**
- Recherche de fournisseurs dans une base de données **Databricks**.
- Vérification du **score RSE** (Responsabilité Sociétale des Entreprises) pour chaque fournisseur.
- Utilisation de **ADK** pour le développement de l'agent.
- **Déploiement** de la solution sur **Cloud Run** et **Agent Engine**.
- Enregistrement du multi-agent sur **Agentspace**.

Responsibilités

- **Tech Lead Consultant**

Environment Technique

- **Python**
- **Agent Developement Kit**
- **Fast API**
- **GCP: Cloud Run, Agent Engine ,Agentspace, Artifact Registry,Cloud Monitoring, Cloud Logging**

Senior ML Engineer -OCTO (Filiale Accenture)

01/2024 - 04/2025

Contexte

- **Définition des guidelines et best practices :** Cadrage et modélisation des données RH, validation des mappings entre systèmes.
- **Mise en place de pipeline automatisé :** Nettoyage, structuration, normalisation des données, gestion des valeurs manquantes, génération d'identifiants uniques.
- **Implémentation NLP** : utilisation de Hugging Face pour générer des embeddings et mesurer la similarité cosinus.
- **Accompagnement des équipes** : compréhension des flux, optimisation des échanges inter-systèmes.

MINISTÈRE DES ARMÉES
Liberté Égalité Fraternité

Responsabilités

- Senior ML Engineer

Environnement technique.

- **Github + CI/CD**
- **SQL**
- **Python**
- **Google Cloud Platform :**
- Bigquery
- Airflow

Senior Data Scientist -Natan

05/2022 - 01/2024

Contexte

- Classification des User Stories via LLM, extraction des relations entre celles-ci et génération automatique de code prêt à l'emploi à partir des User Stories en s'appuyant sur LLM et RAG.
- Déploiement robuste du modèle avec CI/CD, architecture microservices, ainsi que logging et monitoring avancés via MLflow, tout en intégrant les exigences métiers.
- **Animation de Formations internes: Longchain, LLM,RAG**
- **Code reviews**

Responsabilités.

- Senior Data Scientist

Environnement technique.

- **Python**
- **Kafka**
- **Docker, Mlflow , github, CI/CD,Dvc**
- **Jira**

Senior Data Scientist -Natan

09/2023 - 01/2024

Contexte.

- Création et entraînement d'un modèle **LSTM** pour la prédiction multi-propriétés de molécules, permettant d'accélérer l'identification de candidats médicaments.
- **Déploiement en production via une architecture microservices**, avec **CI/CD** automatisé pour un flux reproductible et fiable.
- Intégration de **MLOps** : suivi complet avec MLflow pour le logging, le monitoring et le versioning des modèles et données.
- Automatisation des tests unitaires et d'intégration, garantissant la qualité, la robustesse et la traçabilité du modèle.
- Optimisation des workflows, réduisant le temps de déploiement et de test et assurant une mise à jour fiable des modèles.

Responsabilités.

- ML Engineer

Environnement technique.

- **Python , Flask**
- **Gitlab et CI/CD, Mlflow , DVC**

Senior Data Scientist -INOV Technology

12/2019 - 01/2022

Contexte

- Création et industrialisation d'une solution data-driven pour le matching candidats / postes en combinant **Computer Vision (Mask R-CNN, YOLO), OCR et NLP (Spacy, NLTK, Transformers).**
- Extraction automatique des informations clés (ROI) : coordonnées, parcours académique, expériences professionnelles et compétences des candidats.
- Rapprochement et scoring automatique des candidats selon les compétences demandées, facilitant la sélection et le tri des profils.
- Déploiement et industrialisation : **mise en production** sur AWS SageMaker, avec pipelines de training, versioning et monitoring, garantissant scalabilité et fiabilité.
- Développement d'une application Django pour l'intégration et la visualisation des résultats.
- Code reviews et bonnes pratiques **MLOps** pour assurer la qualité, la maintenabilité et la traçabilité des modèles.

Responsabilités

- Senior Data Scientist

Environnement technique.

- **Django**
- **SQL**
- **Python**
- **NLP: spacy , nltk,transformers**
- **Computer Vision : YOLO(Darknet -CNN)**
- **AWS: SAGEMAKER : SageMaker pour l'industrialisation et la mise à l'échelle des modèles**

Senior Data Scientist-INOV Technology

12/2019 - 01/2022

Contexte

- Génération automatique de bases de données de factures pour faciliter les tests et analyses.
- **Création d'un outil d'anonymisation des données via Tkinter et Faker**, garantissant la confidentialité.
- Extraction des zones clés (client, produits, entreprise) avec **Mask R-CNN, suivie d'une reconnaissance de texte par OCR utilisant des transformers.**
- Développement d'une application web Django intégrant les aspects métier pour une exploitation optimale des données extraites.
- Mise en place et respect des bonnes pratiques **MLOps** pour assurer la robustesse, la traçabilité et la scalabilité des modèles.

Responsabilités.

- Senior Data Scientist

Senior Data Scientist -INOV Technology

Data Scientist-INOV Technology

12/2019 - 01/2022

Contexte & Réalisations:

- **Conception et développement d'un modèle DeepSurv** (extension deep learning du modèle de Cox) pour prédire avec précision le temps de survie des patients, en intégrant données cliniques et CT Scan.
- **Industrialisation et mise en production via une application web Django**, permettant la gestion des données, l'entraînement automatisé du modèle et la visualisation interactive des résultats.
- Mise en place de pipelines robustes pour le traitement des données et le suivi des performances du modèle (monitoring, logging et versioning).
- **Impact clinique : outil support pour les équipes médicales, facilitant la prise de décision et la priorisation des traitements.**

Responsabilités.

- Data Scientist

Environnement technique.

- **Gitlab + CI/CD**
- **DVC ,MLFLOW**
- **Postgres**
- **Python , Django**

Data Scientist-INOV Technology

12/2019 - 01/2022

Contexte & Réalisations:

Mise en place d'un système automatisé de lecture des chiffres affichés sur des compteurs d'eau à partir d'images.

- **Détection des régions d'intérêt (ROI)** contenant les chiffres à l'aide du modèle **Mask R-CNN**, entraîné pour localiser précisément les zones utiles sur les compteurs.
- **Reconnaissance des chiffres** via un modèle **CRNN (Convolutional Recurrent Neural Network)**, combinant les capacités de détection spatiale (CNN) et de séquençage temporel (RNN) pour lire les digits alignés.
- **OCR personnalisé** pour extraire le texte avec fiabilité à partir des ROI détectés, notamment dans des conditions de faible éclairage ou de qualité d'image variable.
- **Développement d'un pipeline complet** d'inférence, de la détection à la prédiction, avec gestion des erreurs et reporting automatisé.
- **Enrichissement métier :** prise en compte des contraintes spécifiques du domaine (format des compteurs, vérification de cohérence, traitement des anomalies).

Responsabilités.

- Data Scientist